UNIVERSIDAD POLITÉCNICA DE MADRID

Grado en Ciencia de Datos e Inteligencia Artificial

Análisis de Redes Complejas y Biogeografía del Triásico (Pangea)

Computación Social y Personalización

Raúl Fernández · Aitor Nieto · Juan Carlos Cintas · Javier Riscos

Curso 2025-2026

Resumen

Este trabajo presenta un análisis de redes complejas aplicado a la biogeografía del Triásico. A partir de los registros fósiles de la Paleobiology Database (PBDB), se construye una red de co-ocurrencia entre yacimientos terrestres de Pangea, donde dos yacimientos se conectan si comparten géneros fósiles. La red resultante (943 nodos, 9.210 aristas) se analiza topológicamente y se somete a detección de comunidades mediante el algoritmo de Louvain, obteniendo una modularidad Q = 0,72 que confirma la existencia de macro-biomas diferenciados en el supercontinente. Se compara la estructura con modelos nulos (Erdős-Rényi, Barabási-Albert, Watts-Strogatz) y se cuantifica el sesgo de muestreo paleontológico mediante test de Chi-cuadrado y coeficiente de Cramér. Los resultados sugieren que, a pesar de la continuidad continental, Pangea albergaba regiones biogeográficas distinguibles, probablemente determinadas por gradientes climáticos latitudinales y barreras geográficas internas como el mar de Tetis y las cadenas montañosas hercinianas.

1. Introducción

Durante el período Triásico (252–201 Ma), la totalidad de las masas continentales estaban unidas en el supercontinente Pangea. Esta configuración geográfica única plantea una pregunta fundamental para la paleobiogeografía: si todos los continentes estaban conectados físicamente, ¿existían biomas diferenciados o la fauna se distribuía de forma homogénea?

La pregunta no es trivial. Por un lado, la ausencia de barreras oceánicas debería haber facilitado la dispersión de organismos a través de todo el supercontinente, favoreciendo una fauna cosmopolita. Por otro lado, la enorme extensión latitudinal de Pangea —desde el polo sur hasta latitudes boreales altas— implica la existencia de gradientes climáticos intensos que podrían haber actuado como barreras ecológicas efectivas. Además, elementos geográficos internos como el mar de Tetis, la cadena montañosa herciniana y las zonas áridas ecuatoriales podrían haber fragmentado la distribución faunística aún sin separación oceánica.

Para abordar esta cuestión se aplican técnicas de análisis de redes complejas sobre datos del registro fósil. Se modela la relación entre yacimientos paleontológicos como una red de co-ocurrencia ponderada, donde el peso de cada conexión refleja el número de géneros fósiles compartidos. La detección de comunidades sobre esta red permite identificar agrupaciones de yacimientos con faunas similares, interpretables como macro-biomas del Triásico.

Este enfoque combina la ingeniería de datos (ETL sobre PBDB), la teoría de redes complejas (métricas topológicas, modelos nulos) y la algorítmica de inteligencia artificial (Louvain, Girvan-Newman, InfoMap) para extraer conocimiento biológico de datos paleontológicos. La ventaja de esta metodología frente a aproximaciones clásicas (como la simple comparación de listas faunísticas) es que permite cuantificar la estructura de la relación entre yacimientos de forma global, detectar agrupaciones no evidentes a simple vista y evaluar la robustez estadística de los patrones encontrados.

2. Datos y Metodología

2.1 Fuente de datos

Se utiliza la Paleobiology Database (paleobiodb.org), la mayor base de datos abierta de ocurrencias fósiles del mundo. Se descargan todos los registros del período Triásico con coordenadas paleotectónicas reconstruidas por el modelo GPlates. El dataset crudo contiene más de 70 variables por registro.

Es importante señalar que la PBDB es una base de datos colaborativa donde los registros son introducidos por investigadores de todo el mundo. Esto implica una heterogeneidad inherente en la calidad y cobertura de los datos: las regiones con mayor tradición paleontológica (Norteamérica, Europa, China) están significativamente mejor representadas que África, Sudamérica u Oceanía. Esta asimetría no es un defecto de nuestro trabajo, sino una característica conocida de la disciplina que debemos tener presente al interpretar los resultados.

2.2 Pipeline ETL

La limpieza de datos sigue cuatro pasos:

- **Selección de variables:** Se conservan 7 de las más de 70 columnas disponibles: ID de yacimiento (collection_no), nombre taxonómico aceptado, rango taxonómico, coordenadas paleotectónicas (paleolat, paleolng), ambiente deposicional y placa tectónica asignada por GPlates.
- **Eliminación de nulos estructurales:** Los registros con valores ausentes en columnas críticas (coordenadas, taxonomía) se eliminan sin imputación. La decisión de no imputar es deliberada: rellenar una coordenada paleotectónica con la media destruiría la geolocalización del yacimiento, e inventar un nombre taxonómico carecería de sentido biológico.
- **Extracción del género taxonómico:** A partir del nombre binomial (p. ej., "Coelophysis bauri") se extrae la primera palabra como género. Se filtran prefijos informales como cf., aff. y nr., que indican identificaciones tentativas.
- **Filtrado por ambiente deposicional:** Se conservan únicamente 9 categorías de ambientes terrestres (terrestre, fluvial, lacustre, aluvial, eólico, llanura de inundación, delta, pantano, turbera), excluyendo ambientes marinos. Esta decisión se fundamenta en que los organismos marinos tienen patrones de dispersión fundamentalmente distintos (corrientes oceánicas frente a barreras terrestres), y su inclusión contaminaría las comunidades detectadas.

2.3 Construcción de la red

Se construye un grafo bipartito B = (U, V, E) donde U es el conjunto de yacimientos, V el conjunto de géneros fósiles, y existe una arista (u, v) si el género v ha sido encontrado en el yacimiento u. La proyección ponderada sobre U genera la red unipartita G, donde el peso $w(u_i, u_j) = |N(u_i) \cap N(u_j)|$ representa el número de géneros compartidos entre dos yacimientos.

Se aplica una poda eliminando aristas con peso igual a 1 (un único género compartido), que representan el 75% de las conexiones y corresponden mayoritariamente a géneros cosmopolitas. Los nodos aislados resultantes se eliminan. La decisión de podar en peso = 1 es conservadora: la mediana de pesos ya es 1, lo que indica que la mayoría de conexiones son débiles. La validación de este umbral se realiza a posteriori mediante análisis de sensibilidad.

Conviene reflexionar sobre lo que implica esta poda. Un peso de 1 significa que dos yacimientos comparten un único género. Dado que existen géneros cosmopolitas presentes en decenas de yacimientos a lo largo de todo Pangea (como Lystrosaurus en el Triásico temprano), estas conexiones de peso unitario reflejan más la ubicuidad del género que una afinidad biogeográfica real entre los yacimientos. Eliminarlas prioriza la especificidad de las conexiones sobre la cobertura.

2.4 Detección de comunidades

Se aplica el algoritmo de Louvain (Blondel et al., 2008) con resolución $\gamma = 1{,}0$ para particionar la red en comunidades que maximicen la modularidad Q. Se compara con Girvan-Newman (divisivo, basado en edge betweenness), Greedy Modularity (aglomerativo, Newman 2004) e InfoMap (basado en flujo de información, Rosvall y Bergstrom 2008). La modularidad se evalúa según el umbral de Newman: $Q > 0{,}3$ indica estructura modular significativa.

La elección de múltiples algoritmos no es redundante, sino una estrategia de validación cruzada. Cada algoritmo optimiza un criterio distinto (modularidad, betweenness, flujo), por lo que la convergencia de sus resultados proporciona una garantía más fuerte de que la estructura detectada es genuina y no un artefacto del método elegido.

3. Resultados

3.1 Descripción de la red

La red biogeográfica resultante tras la poda contiene 943 yacimientos y 9.210 conexiones. La Tabla 1 resume las métricas topológicas principales.

Tabla 1. Métricas topológicas de la red biogeográfica de Pangea

Nodos (yacimientos)	943	
Aristas (conexiones)	9.210	
Componentes conexas	23	Gigante: 883 (93,6%)
Grado medio ⟨k⟩	19,53	
Grado máximo	188	
Clustering global	0,5277	
Distancia geodésica media	4,09	
Diámetro	12	
Asortatividad por grado	0,0646	Neutra
Clique máximo	36 nodos	

Varias de estas métricas merecen comentario. El grado medio de 19,53 indica que cada yacimiento comparte géneros con aproximadamente 20 otros yacimientos, lo cual sugiere una red moderadamente densa. Sin embargo, el grado máximo de 188 revela la existencia de hubs extremos que concentran una cantidad desproporcionada de conexiones. Esta heterogeneidad se cuantifica formalmente en el análisis de la distribución de grados.

El clustering global de 0,53 es notablemente alto y tiene una interpretación biogeográfica directa: si el yacimiento A comparte géneros con B, y B comparte con C, es muy probable que A y C también compartan géneros. Esto refleja la existencia de "vecindarios biogeográficos" cohesivos donde los yacimientos de una misma región comparten faunas similares.

La componente gigante agrupa al 93,6% de los nodos. Las 22 componentes restantes representan pequeños clusters de yacimientos aislados, posiblemente correspondientes a localidades con faunas endémicas o con registros fósiles demasiado fragmentarios para conectar con el resto de la red.

3.2 Distribución de grados

La distribución de grados presenta una forma de cola pesada (heavy-tailed), característica de redes donde unos pocos nodos acumulan la mayoría de conexiones. El ajuste formal mediante el paquete powerlaw (Clauset et al., 2009) indica que el mejor modelo es una distribución lognormal con exponente $\alpha = 2{,}67$, frente a la hipótesis de ley de potencias pura o exponencial.

Este resultado es coherente con lo que se observa en muchas redes biológicas y geográficas: la presencia de hubs no es tan extrema como en una red libre de escala pura, pero sí existe una cola significativa que separa la red de un modelo aleatorio tipo Erdős-Rényi, donde los grados se distribuirían según una Poisson simétrica.

3.3 Comparación con modelos nulos

La Tabla 2 compara las métricas de la red real con redes sintéticas del mismo tamaño y densidad generadas por tres modelos.

Tabla 2. Comparación con modelos nulos (N = 30 redes sintéticas por modelo)

Pangea (real)	0,5277	4,09
Erdős-Rényi	≈0,023	≈2,57
Barabási-Albert	≈0,058	≈2,53
Watts-Strogatz	≈0,512	≈3,14

El clustering real (0,53) es 22 veces superior al de Erdős-Rényi (0,023), mientras que la distancia media (4,09) se mantiene relativamente corta. Esta combinación —alto clustering con distancias globales reducidas— es la firma inequívoca de una **red small-world** (Watts y Strogatz, 1998).

La comparación con cada modelo aporta información distinta. Erdős-Rényi sirve como línea base de aleatoriedad pura: el hecho de que nuestra red se aleje tanto en clustering confirma que la estructura no es un artefacto del tamaño o la densidad. Barabási-Albert reproduce la cola pesada de la distribución de grados pero no el clustering, lo que indica que la conexión preferencial por sí sola no explica la cohesión local observada. Watts-Strogatz es el modelo que mejor se aproxima al clustering real, lo que sugiere que la red biogeográfica de Pangea tiene una topología similar a una red de mundo pequeño con reconexiones locales.

Desde una perspectiva biogeográfica, la propiedad de mundo pequeño implica que, aunque los yacimientos se organizan en vecindarios faunísticos densos, existen “corredores” que conectan regiones distantes con relativamente pocos saltos. Estos corredores podrían corresponder a rutas de dispersión faunística a través de zonas de transición ecológica.

3.4 Detección de comunidades

Tabla 3. Comparación de algoritmos de detección de comunidades

Louvain (comp. gigante)	14	0,7186
Greedy Modularity	11	0,6964
Girvan-Newman (sub. 150)	variable	> 0,3

InfoMap (comp. gigante)	≈20	0,66 (aprox.)

Louvain obtiene la mayor modularidad (Q = 0,72), seguido de Greedy Modularity (Q = 0,70). Ambos superan ampliamente el umbral de 0,3, confirmando una estructura de comunidades robusta. Se detectan 5 macro-biomas principales que agrupan el 76% de los yacimientos, más comunidades menores que representan zonas de transición o yacimientos aislados.

Es relevante que InfoMap, que optimiza un criterio completamente distinto a la modularidad (minimización de la descripción de flujos aleatorios), también identifica una partición con estructura significativa. Esto refuerza la conclusión de que la organización en comunidades no es un artefacto del criterio de optimización elegido.

3.5 Interpretación biogeográfica de las comunidades

Las comunidades detectadas por Louvain no son meras agrupaciones matemáticas: al proyectarlas sobre las paleo-coordenadas, se observa que cada comunidad ocupa una región geográfica coherente en Pangea. Aunque no disponemos de reconstrucciones climáticas detalladas para el Triásico, podemos interpretar las principales comunidades a la luz de lo que se conoce sobre la geografía del supercontinente:

- **Comunidades de altas latitudes (Gondwana meridional):** Agrupan yacimientos situados en lo que hoy es Sudamérica, África austral, Antártida e India. La presencia dominante de géneros como Lystrosaurus y Cynognathus en estas regiones es coherente con un clima templado-frío y ecosistemas dominados por terápsidos.
- **Comunidades de Laurasia:** Concentran yacimientos de Norteamérica y Europa. La fauna incluye una mayor proporción de arcosaurios tempranos y dinosauromorfos, consistente con un clima árido a semiárido típico de las latitudes ecuatoriales y subtropicales de Pangea norte.
- **Comunidades de los bloques orientales (China, Sudeste Asiático):** Forman un cluster diferenciado que podría reflejar el relativo aislamiento de los bloques continentales asiáticos, parcialmente separados del núcleo de Pangea por brazos del mar de Tetis durante parte del Triásico.
- **Comunidades de transición:** Yacimientos con alta betweenness centrality pero grado moderado que conectan macro-biomas adyacentes. Estos nodos podrían representar ecotonos —zonas de transición ecológica donde coexistían faunas de regiones distintas—, un fenómeno bien documentado en ecología moderna.

Esta interpretación debe tomarse con cautela, ya que las comunidades también pueden reflejar parcialmente el sesgo de muestreo (véase Sección 4.1). Sin embargo, el hecho de que las comunidades mezclen yacimientos de múltiples placas tectónicas sugiere que no son un simple reflejo de la geografía del muestreo.

3.6 Análisis de nodos importantes

Se identifican dos tipos de nodos relevantes en la red:

Hubs biogeográficos: Yacimientos con grado superior a 100 que actúan como centros de diversidad fósil. Estos hubs se concentran en las placas tectónicas 101 (Laurentia/Norteamérica) y 701 (China). Esto admite una doble lectura: por un lado, estas regiones son las más excavadas, lo que introduce un sesgo de muestreo; por otro, son regiones que durante el Triásico ocupaban posiciones geográficas que favorecían la biodiversidad (latitudes subtropicales con disponibilidad hídrica). Probablemente ambos factores contribuyen al alto grado de estos nodos.

Puentes entre biomas: Yacimientos con alta betweenness centrality pero grado moderado. Estos nodos conectan comunidades distintas y resultan especialmente interesantes porque podrían señalar zonas donde coexistían faunas de macro-biomas adyacentes, funcionando como corredores de dispersión.

3.7 Visualización geográfica

La proyección de las comunidades de Louvain sobre coordenadas actuales de los yacimientos muestra que los macro-biomas, que en Pangea ocupaban regiones contiguas, aparecen fragmentados y dispersos por múltiples continentes modernos. Esta dispersión evidencia visualmente el efecto de la deriva continental sobre la distribución de la fauna del Triásico y constituye una validación cualitativa del resultado algorítmico: si las comunidades fueran aleatorias, no cabría esperar ningún patrón espacial en su proyección geográfica.

4. Discusión

4.1 Sesgo de muestreo

La distribución de yacimientos por placa tectónica revela un sesgo de muestreo significativo: las tres placas más excavadas (101-Norteamérica, 701-China, 305-Europa) concentran el 60% de los yacimientos. Un test de Chi-cuadrado de independencia entre comunidades y placas da un resultado altamente significativo ($p < 0{,}001$), pero el coeficiente de Cramér $V = 0{,}43$ indica una asociación moderada, no total.

El valor de $V = 0{,}43$ merece una reflexión detallada. Si las comunidades fueran un simple reflejo de la geografía del muestreo (es decir, si cada comunidad correspondiera exactamente a una placa tectónica), esperaríamos un V cercano a 1. El valor moderado observado indica que, aunque existe correlación entre comunidad y placa, las comunidades mezclan yacimientos de múltiples placas. Esto es coherente con la hipótesis de que reflejan biomas reales: los biomas del Triásico se extendían a través de varias masas continentales que luego se separaron por la deriva continental.

Dicho esto, no podemos descartar que parte de la estructura detectada sea un artefacto del muestreo diferencial. Las regiones bien muestreadas tienen más yacimientos con los que compartir géneros, lo que podría inflar artificialmente la densidad de conexiones en esas zonas. Una línea de trabajo futuro sería aplicar técnicas de rarefacción o submuestreo estratificado por placa para evaluar la estabilidad de las comunidades bajo diferentes escenarios de muestreo.

4.2 Robustez de los resultados

El análisis de sensibilidad muestra que las comunidades principales se mantienen estables bajo variaciones del parámetro de resolución (γ entre 0,75 y 1,5) y del umbral de poda (peso mínimo entre 2 y 4). La convergencia de tres algoritmos independientes (Louvain, Greedy, Girvan-Newman) e InfoMap sobre una modularidad $Q > 0{,}3$ refuerza la conclusión de que la estructura es genuina y no un artefacto algorítmico.

Es particularmente significativo que la estabilidad se mantenga al variar el umbral de poda. Si las comunidades dependieran críticamente de la eliminación de aristas de peso 1, serían sospechosas de ser un artefacto de nuestra decisión metodológica. El hecho de que persistan con umbrales de 2, 3 y 4 indica que la señal biogeográfica está en las conexiones fuertes, no en las débiles.

4.3 Significado biogeográfico: ¿qué separaba los biomas?

Si Pangea era un único continente, ¿qué barr eras podrían haber generado la diferenciación faunística que detectamos? La literatura paleoclimática sugiere varias candidatas:

- **Gradiente latitudinal:** Pangea se extendía desde cerca del polo sur hasta latitudes boreales medias-altas. La diferencia climática entre las regiones polares y ecuatoriales era sustancial,

aunque el gradiente térmico del Triásico era más suave que el actual por la ausencia de casquetes polares permanentes.

- **Aridez ecuatorial:** La zona ecuatorial de Pangea era extremadamente árida, formando una barrera de desiertos que podría haber limitado la dispersión de faunas entre las mitades norte (Laurasia) y sur (Gondwana) del supercontinente.
- **Mar de Tetis:** El océano de Tetis penetraba profundamente en el margen oriental de Pangea, separando parcialmente los bloques continentales asiáticos del núcleo del supercontinente.
- **Cadenas montañosas interiores:** Las montañas hercinianas (relictos de la orogenesis variscía) y otras formaciones topográficas internas podrían haber actuado como barreras locales.

Nuestro análisis de redes no puede discriminar cuál de estos factores es el dominante, ya que trabajamos con datos de co-ocurrencia y no con variables ambientales directas. Sin embargo, el hecho de que las comunidades detectadas se alineen razonablemente con las grandes divisiones paleogeográficas (Gondwana sur, Laurasia ecuatorial, bloques orientales) sugiere que los gradientes climáticos y la geografía del mar de Tetis fueron los factores principales.

4.4 Limitaciones

Reconocemos las siguientes limitaciones del presente trabajo:

- La poda de aristas con peso 1 no se valida contra un modelo nulo de co-ocurrencia (p. ej., Configuration Model). Este modelo generaría redes aleatorias preservando la distribución de grados, lo que permitiría distinguir con mayor rigor qué conexiones son estadísticamente significativas.
- Las paleo-coordenadas tienen incertidumbre inherente al modelo de reconstrucción tectónico GPlates. Las posiciones de los yacimientos en Pangea son estimaciones con márgenes de error de decenas a centenares de kilómetros.
- La resolución taxonómica a nivel de género puede enmascarar diferencias relevantes a nivel de especie. Dos yacimientos que comparten un género podrían contener especies distintas de ese género, lo que sobreestimaría su afinidad biogeográfica.
- Girvan-Newman se ejecutó sobre un subgrafo de 150 nodos por limitaciones computacionales (complejidad $O(m^2 \cdot n)$), lo que debilita parcialmente la comparación con los otros algoritmos que operan sobre la red completa.
- No se incorporan variables temporales. El Triásico abarca 50 millones de años, durante los cuales los biomas evolucionaron. Una segmentación por subperíodos (Triásico inferior, medio, superior) podría revelar dinámicas de cambio que nuestro análisis estático no captura.

5. Conclusiones

El análisis de la red de co-ocurrencia fósil de Pangea permite extraer las siguientes conclusiones:

- **Pangea presentaba biomas terrestres diferenciados** a pesar de la continuidad continental, con una modularidad Q = 0,72 que indica una partición marcada de la fauna. Las comunidades detectadas se alinean con las grandes divisiones paleogeográficas del supercontinente.
- **La red posee propiedades de mundo pequeño (small-world):** clustering 22x superior al azar combinado con distancias geodésicas cortas (media 4,09). Esto refleja vecindades biogeográficas cohesivas conectadas por corredores de dispersión faunística.
- **La distribución de grados es de cola pesada** (mejor ajuste: lognormal con $\alpha = 2{,}67$), indicando la existencia de hubs paleontológicos que concentran la diversidad. Estos hubs son parcialmente atribuibles al sesgo de muestreo.
- **La proyección sobre coordenadas modernas** muestra la fragmentación de los biomas originales por la deriva continental, validando visualmente la detección algorítmica.
- **La convergencia de cuatro algoritmos independientes** (Louvain, Greedy, Girvan-Newman, InfoMap) sobre una estructura modular significativa refuerza la conclusión de que los patrones son genuinos.
- **El sesgo de muestreo de la PBDB** (Cramér V = 0,43) modera pero no invalida las conclusiones, ya que las comunidades mezclan múltiples placas tectónicas.

En conjunto, este trabajo demuestra que las técnicas de análisis de redes complejas son una herramienta valiosa para la paleobiogeografía, capaz de revelar patrones macroecológicos a partir de datos de registro fósil. Las líneas de trabajo futuro incluyen la segmentación temporal del análisis, la validación con modelos nulos de co-ocurrencia, y la integración de datos paleoclimáticos para correlacionar las comunidades detectadas con gradientes ambientales reconstruidos.

6. Herramientas y Código

El proyecto se implementa en Python 3.11 con las siguientes librerías: pandas, numpy, NetworkX, GeoPandas, matplotlib, pyvis, powerlaw, scipy e infomap. La visualización de la red se realiza en Gephi 0.10 (archivo GEXF) y como visualización interactiva HTML (pyvis). La presentación de resultados se despliega como aplicación web interactiva mediante Streamlit. Todo el código se distribuye en dos cuadernos Jupyter: EDA_01.ipynb (pipeline ETL y construcción de la red) y Analisis_Topologico_Pangea.ipynb (métricas, modelos nulos, comparación de algoritmos y sesgo de muestreo).

7. Referencias

Blondel, V. D., Guillaume, J. L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. Journal of Statistical Mechanics, P10008.

Clauset, A., Shalizi, C. R., & Newman, M. E. (2009). Power-law distributions in empirical data. SIAM Review, 51(4), 661-703.

Girvan, M., & Newman, M. E. (2002). Community structure in social and biological networks. PNAS, 99(12), 7821-7826.

Newman, M. E. (2004). Finding and evaluating community structure in networks. Physical Review E, 69(6), 066133.

Rosvall, M., & Bergstrom, C. T. (2008). Maps of random walks on complex networks reveal community structure. PNAS, 105(4), 1118-1123.

Watts, D. J., & Strogatz, S. H. (1998). Collective dynamics of small-world networks. Nature, 393(6684), 440-442.

Paleobiology Database. https://paleobiodb.org/